گزارش نتیجهٔ پروژه: اولویت‌بندی مشتریان برای کمپین ایمیلی

تحلیل و پیش‌بینی خرید مشتریان (داده‌ی Hillstrom) — ارائه به مدیر بازاریابی

تاریخ گزارش: ۲۷ مهر ۱۴۰۵ (۱۹ اکتبر ۲۰۲۶) | منبع اعداد: خروجی‌های ذخیره‌شده‌ی نوت‌بوک‌های ۱ تا ۳ | نوت‌بوک‌ها در این گزارش اجرا نشده‌اند

۱. خلاصه‌ی مدیریتی

۳۷٫۴٪
خریداران آزمون که در ۱۷٫۴٪ بالای فهرست افتادند (۴۳ از ۱۱۵)؛ فهرست تصادفی انتظاراً حدود ۱۷٫۴٪ می‌گیرد

۲٫۱۵
Lift در همین ظرفیت روی آزمون؛ در اعتبارسنجی ۱٫۷۱ (مدل جنگل تصادفی)

۰٫۰۳۰
Average Precision آزمون، در برابر نرخ پایه‌ی ۰٫۰۱۰ (حدود سه برابر)

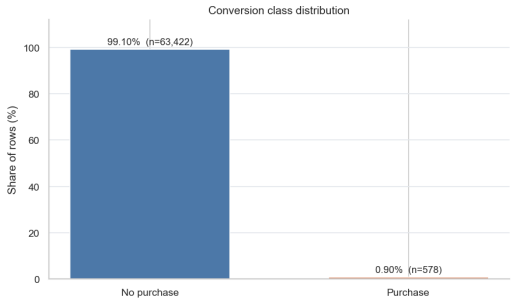
آماده‌ی استقرار نیست
سیگنال ضعیف، آزمون کوچک (۱۱۵ خریدار)، بدون شناسه‌ی مشتری

پرسش کسب‌وکار	ظرفیت ارسال محدود است (حدود ۱۰٬۰۰۰ ایمیل، یعنی ۱۷٫۴٪ از ۵۷٬۴۳۸ ردیف مجاز). ایمیل اول باید به چه کسانی برسد؟ مدل فقط با اطلاعات پیش از کمپین رتبه‌بندی می‌کند.
مدل منتخب	جنگل تصادفی (`Random Forest`)، با بیشترین میانگین `Average Precision` در اعتبارسنجی تودرتو: `XGBoost` ۰٫۰۲۰۷ ± ۰٫۰۰۳۵ (۰٫۰۱۷۶ ± ۰٫۰۰۲۱) کمی پایین‌تر است؛ اختلاف از انحراف معیار جنگل تصادفی کمتر است و برتری قطعی نیست.
معیار اصلی انتخاب	`Average Precision`، نه `Accuracy`؛ چون فقط حدود ۱٪ ردیف‌ها خریدارند و پیش‌بینی «هیچ‌کس نمی‌خرد» ۹۹٫۱٪ دقت دارد ولی هیچ خریداری پیدا نمی‌کند.
نتیجه در ظرفیت ارسال	روی بخش آزمون (۱۱٬۴۸۸ ردیف، ۱۱۵ خریدار): انتخاب ۲٬۰۰۱ ردیف، یافتن ۴۳ خریدار، `Precision` حدود ۲٫۱٪ و `Recall` حدود ۳۷٫۴٪. قاعده‌ی ساده‌ی کسب‌وکار در همان اندازه ۳۲ خریدار پیدا می‌کند. در اعتبارسنجی، `Lift` جنگل تصادفی ۱٫۷۱ است.
محدودیت حیاتی	تعداد کم خریدار (۱۱۵ در آزمون) و سیگنال ضعیف؛ نبود شناسه‌ی یکتای مشتری (نتایج در سطح ردیف است)؛ امتیازها احتمال واقعی خرید نیستند.
آنچه پیش‌بینی نمی‌شود	اثر علّی ایمیل، سود یا درآمد افزایشی. مدل می‌گوید چه کسی احتمالاً می‌خرد، نه چه کسی به‌خاطر ایمیل می‌خرد.
آمادگی و پیشنهاد	برای استقرار عملیاتی آماده نیست. پیشنهاد: از رتبه‌بندی فقط برای اولویت‌بندی آزمایشی استفاده شود و اثر واقعی کمپین با آزمون کنترل‌شده (`A/B Test`) سنجیده شود؛ کارهای لازم در بخش ۶ اولویت‌بندی شده‌اند.

تفاوت پیش‌بینی با اثر علّی: این گزارش «تمایل به خرید» را رتبه‌بندی می‌کند. هیچ‌یک از اعداد، افزایش فروش یا اثر کمپین را ثابت نمی‌کند.

۲. مسئله و داده

شرکت می‌خواهد پیش از اجرای کمپین، مشتریان را بر اساس احتمال خرید اولویت‌بندی کند تا ظرفیت محدود ایمیل به محتمل‌ترین‌ها برسد. متغیر هدف `conversion` است (۱ = خرید). داده‌ی اصلی ۶۴,۰۰۰ ردیف و ۵۷۸ خرید دارد؛ نرخ خرید ۰٫۹۰٪ است. داده **شناسه‌ی یکتای مشتری ندارد**؛ پس شمارش‌ها در سطح ردیف است، نه افراد تأییدشده.



شکل ۱ — توزیع هدف: ۹۹٫۱۰٪ غیرخریدار (۶۳,۴۲۲) و ۰٫۹۰٪ خریدار (۵۷۸).

تعداد ردیف‌ها	۶۴,۰۰۰
ستون‌ها	۱۳ (شامل پرچم ردیف تکراری)
خریداران	۵۷۸ (۰٫۹۰٪)
دقت قاعده‌ی «هیچ‌کس نمی‌خرد»	۹۹٫۱٪، با صفر خریدار یافته‌شده
شناسه‌ی مشتری	ندارد

> **برداشت:** چون خریدار بسیار کم است، `Accuracy` به‌تنهایی گمراه‌کننده است و کیفیت رتبه‌بندی با معیارهایی مثل `Average Precision` و `Lift` سنجیده می‌شود.

الگوهای توصیفی در تحلیل اکتشافی (نه علّی): نرخ خرید ردیف‌هایی با آخرین خرید در ماه‌های ۱ تا ۳ برابر ۱٫۲۴٪ و بالاتر از میانگین ۰٫۹۰٪ است؛ گروه خرج سال قبل «۱,۰۰۰ دلار به بالا» ۲٫۱۴٪ است (۲۸ از ۱,۳۰۸ ردیف). این نرخ‌ها فقط توصیف داده‌اند و ثابت نمی‌کنند ویژگی‌ها باعث خرید می‌شوند.

۳. آماده‌سازی داده و طراحی مدل

- **کنترل کیفیت (نوت‌بوک ۱):** مقدار گمشده نداشت؛ دامنه‌ها، گروه‌های خرج و سازگاری خروجی‌ها بررسی و تأیید شد. املای `Surburban` در نسخه‌ی تمیز به `Suburban` اصلاح شد (۲۸,۷۷۶ ردیف). مقادیر پرت معتبر حذف نشدند.
- **ردیف‌های تکراری:** ۶,۵۶۲ ردیف، پس از اولین تکرار دقیق، پرچم‌گذاری شد (۷,۶۳۴ ردیف در گروه‌های تکراری). در پاک‌سازی همه‌ی ردیف‌ها نگه داشته شدند؛ این ردیف‌ها فقط در **مدل‌سازی** کنار گذاشته شدند. چون شناسه‌ی مشتری نداریم، تکرار دقیق ثابت نمی‌کند یک نفر چندبار ثبت شده است. مجموعه‌ی مدل‌سازی ۵۷,۴۳۸ ردیف است و چون هر ۵۷۸ خریدار در آن می‌مانند، نرخ خرید به حدود ۱٫۰۱٪ می‌رسد.
- **ورودی‌های پیش از کمپین:** `recency`، `history`، `mens`، `womens`، `newbie`، `zip_code` و `channel`. ستون `history_segment` حذف شد چون فقط نسخه‌ی گروه‌بندی‌شده‌ی `history` است. پیش‌پردازش (لگاریتم `history`، مقیاس‌دهی، کدگذاری دسته‌ها) درون یک `Pipeline` و فقط روی داده‌ی آموزشِ هر بخش انجام می‌شود.
- **تقسیم داده:** آموزش ۴۵,۹۵۰ ردیف (۴۶۳ خریدار) و آزمون ۱۱,۴۸۸ ردیف (۱۱۵ خریدار)، با حفظ نسبت خریدار. آزمون فقط از ردیف‌هایی ساخته شد که ارزیابی قبلی ندیده بود. انتخاب مدل و تنظیم پارامتر فقط با اعتبارسنجی روی بخش آموزش انجام شد؛ آزمون برای تنظیم، انتخاب مدل یا آستانه استفاده نشد.

نشت اطلاعات (Data Leakage)

`visit` و `spend` نتیجه‌ی بعد از کمپین‌اند و `segment` همان گروه تخصیص کمپین است؛ هیچ‌کدام پیش از کمپین در دسترس نیستند. برای نشان‌دادن اثر نشت، یک رگرسیون لجستیک روی سه مجموعه‌ی ورودی اعتبارسنجی شد:

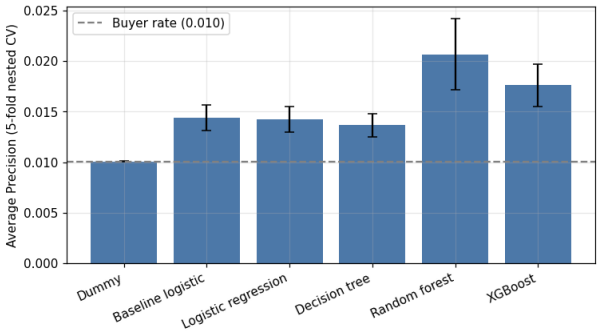
مجموعه‌ی ورودی	ROC-AUC	AP	برداشت
A: فقط ویژگی‌های پیش از کمپین	۰٫۵۸۵	۰٫۰۱۴	سناریوی واقعی؛ مبنای همه‌ی مدل‌ها
B: A به‌علاوه‌ی `visit`	۰٫۹۲۹	۰٫۰۷۵	غیرواقعی؛ بازدید پس از کمپین رخ می‌دهد
C: A به‌علاوه‌ی `spend`	۱٫۰۰۰	۱٫۰۰۰	نشت کامل؛ `spend > 0` همان خرید است

۴. روش و ارزیابی مدل‌ها

مدل‌ها: دو مبنا (`Dummy` و رگرسیون لجستیک پیش‌فرض)، سه مدل اجباریِ کاتالوگ (رگرسیون لجستیک، درخت تصمیم، جنگل تصادفی) و `XGBoost` به‌عنوان مدل مقایسه‌ای اختیاری. پارامترها با اعتبارسنجی **تودرتو** تنظیم شدند: بخش داخلی (۳ بخش) پارامتر را با `Average Precision` انتخاب می‌کند و بخش بیرونی (۵ بخش) عملکرد را روی داده‌ای می‌سنجد که مدل ندیده است. بنابراین عدد گزارش‌شده خوش‌بینانه نیست. نتایج زیر میانگین ± انحراف معیار روی ۵ بخش بیرونی‌اند؛ هر بخش حدود ۹۰ خریدار دارد، پس اختلاف‌های کوچک نویز است.

مدل	AP (میانگین ± انحراف)	ROC-AUC (میانگین ± انحراف)	نقطه‌ی عملکرد: ۱۷٫۴٪ بالا (حدود ۱٬۶۰۰ نفر در هر بخش)		
			Precision	Recall	Lift
Dummy	۰٫۰۱۰۱ ± ۰٫۰۰۰۱	۰٫۵۰۰ ± ۰٫۰۰۰	—	—	—
رگرسیون لجستیک پیش‌فرض (مبنا)	۰٫۰۱۴۴ ± ۰٫۰۰۱۳	۰٫۵۸۵ ± ۰٫۰۲۲	—	—	—
رگرسیون لجستیک (تنظیم‌شده)	۰٫۰۱۴۲ ± ۰٫۰۰۱۳	۰٫۵۸۵ ± ۰٫۰۲۲	۰٫۰۱۶	۰٫۲۷۲	۱٫۵۶
درخت تصمیم	۰٫۰۱۳۶ ± ۰٫۰۰۱۲	۰٫۵۷۹ ± ۰٫۰۱۴	۰٫۰۱۴	۰٫۲۴۰	۱٫۳۸
جنگل تصادفی (منتخب)	**۰٫۰۲۰۷ ± ۰٫۰۰۳۵**	**۰٫۶۲۵ ± ۰٫۰۲۷**	**۰٫۰۱۷**	**۰٫۲۹۸**	**۱٫۷۱**
XGBoost (اختیاری)	۰٫۰۱۷۶ ± ۰٫۰۰۲۱	۰٫۶۰۹ ± ۰٫۰۲۴	۰٫۰۱۷	۰٫۲۸۷	۱٫۶۵

«—»: برای این مدل‌ها در خروجی‌های ذخیره‌شده گزارش نشده است.



شکل ۲ — Average Precision اعتبارسنجی تودرتو؛ خط خاکستری: نرخ خرید پایه (۰٫۰۱۰).

برداشت: فقط جنگل تصادفی و XGBoost بالاتر از مبنای رگرسیون لجستیک‌اند و میله‌های خطای این دو همپوشانی دارد. اختلاف جنگل تصادفی و XGBoost (۰٫۰۰۳۱) از انحراف معیار جنگل تصادفی (۰٫۰۰۳۵) کمتر است؛ جنگل تصادفی بر اساس بیشترین میانگین انتخاب شد، نه به‌دلیل برتری اثبات‌شده.

رگرسیون لجستیک تنظیم‌شده نسبت به مبنای پیش‌فرض بهبودی نداد. همه‌ی مدل‌ها فقط کمی از Dummy بهترند؛ سیگنال ضعیف است.

معیارهای خواسته‌شده‌ی کاتالوگ و وضعیت گزارش آن‌ها

معیار	اعتبارسنجی (چهار مدل)	آزمون (جنگل تصادفی، ۱۷٫۴٪ بالا)
Accuracy	گزارش‌نشده — نیازمند تکمیل	۰٫۸۲۳ (محاسبه‌شده از ماتریس خطای ذخیره‌شده؛ برای انتخاب مدل بی‌معنی است)
Precision	در جدول بالا	۰٫۰۲۱
Recall	در جدول بالا	۰٫۳۷۴
F1	گزارش‌نشده — نیازمند تکمیل	۰٫۰۴۱
ROC-AUC	در جدول بالا	۰٫۶۵۲
PR-AUC	به‌جای مساحت جداگانه‌ی زیر منحنی، Average Precision گزارش شده است (آزمون: ۰٫۰۳۰۳ در برابر نرخ پایه‌ی ۰٫۰۱۰).	
ماتریس خطا	گزارش‌نشده — نیازمند تکمیل	شکل ۳

چرا Accuracy کافی نیست: با نرخ خرید ۱٪، حتی مدلی که هیچ مشتری را انتخاب نکند حدود ۹۹٪ دقت دارد. در انتخاب ۱۷٫۴٪ بالا نیز Accuracy (حدود ۸۲٪) صرفاً نشان می‌دهد چند ردیف انتخاب نشده‌اند، نه اینکه خریداران خوب پیدا شده‌اند.

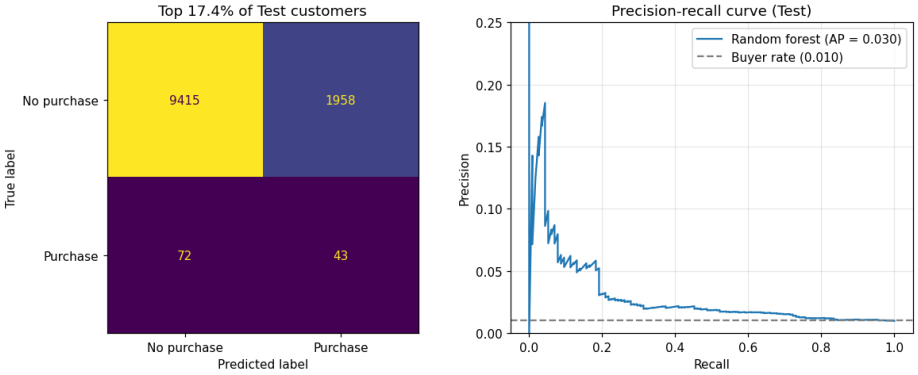
۵. نتیجه‌ی هدف‌گیری و معنای خطاها

نتایج این بخش مربوط به **بخش آزمون** است (۱۱٬۴۸۸ ردیف و ۱۱۵ خریدار) و جدا از اعتبارسنجی گزارش می‌شود. مدل منتخب (جنگل تصادفی با max_depth=4 و min_samples_leaf=30) روی همه‌ی داده‌ی آموزش آموزش دید و آزمون فقط یک بار امتیازدهی شد. در هر ردیف جدول، «n» تعداد ردیف انتخاب‌شده از آزمون است.

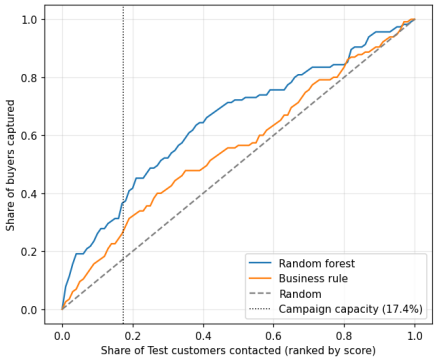
سهم انتخاب‌شده	n	جنگل تصادفی				قاعده‌ی ساده	
		خریدار	Precision	Recall	Lift	خریدار	Lift
۵٪	۵۷۵	۲۲	۰٫۰۳۸	۰٫۱۹۱	۳٫۸۲	۱۱	۱٫۹۱
۱۰٪	۱,۱۴۹	۳۰	۰٫۰۲۶	۰٫۲۶۱	۲٫۶۱	۱۹	۱٫۶۵
۱۷٫۴٪ (ظرفیت ارسال)	**۲,۰۰۱**	**۴۳**	**۰٫۰۲۱**	**۰٫۳۷۴**	**۲٫۱۵**	**۳۲**	**۱٫۶۰**
۲۰٪	۲,۲۹۸	۴۸	۰٫۰۲۱	۰٫۴۱۷	۲٫۰۹	۳۷	۱٫۶۱
۳۰٪	۳,۴۴۷	۶۰	۰٫۰۱۷	۰٫۵۲۲	۱٫۷۴	۴۸	۱٫۳۹

قاعده‌ی ساده: `recency <= 3` و `history` بالاتر از چارک ۷۵ داده‌ی آموزش (نه `spend`). برش از آموزش آمده و روی آزمون تنظیم نشده است. امتیازهای قاعده سه‌سطحی‌اند و تساوی‌ها تصادفی شکسته شده‌اند.

برداشت: در هر اندازه‌ی کمپین، مدل خریدار بیشتری از قاعده‌ی ساده پیدا می‌کند (۴۳ در برابر ۳۲ در ظرفیت ارسال)، ولی با ۱۱۵ خریدار این اختلاف نشانه است، نه برآورد دقیق. برای برنامه‌ریزی محافظه‌کارانه‌تر، `Lift` اعتبارسنجی (۱٫۷۱) را در کنار `Lift` آزمون (۲٫۱۵) ببینید. این جدول ارزیابی روی بخش آزمون است و **فهرست نهایی ۱۰,۰۰۰ مشتری نیست:** چون شناسه‌ی مشتری نداریم، خروجی فعلی فهرست تماس عملیاتی نیست.



شکل ۳ — ماتریس خطا برای ۱۷٫۴٪ بالای آزمون (راست: منحنی Recall–Precision؛ محور عمودی تا ۰٫۲۵ محدود شده است).



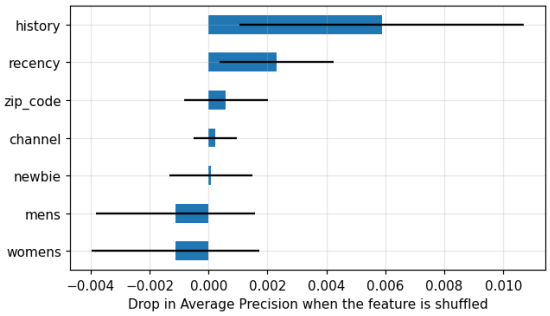
شکل ۴ — سهم خریداران گرفته‌شده روی آزمون (خط نقطه‌چین عمودی: ظرفیت ۱۷٫۴٪).

معنای خطاها در ظرفیت ارسال:

- **`False Positive` (۱,۹۵۸ ردیف):** ظرفیت ایمیل برای کسی مصرف شده که نخریده است.
- **`False Negative` (۷۲ ردیف):** خریداری که در فهرست نبوده و فرصت تماس با او از دست رفته است.
- حدود ۹۸٪ ردیف‌های انتخاب‌شده خریدار نبوده‌اند؛ مدل فقط بهتر از انتخاب تصادفی رتبه می‌دهد، نه اینکه فهرستی تقریباً خالص از خریدار بسازد.
- هزینه‌ی مالی هر خطا بدون هزینه‌ی ارسال ایمیل و حاشیه‌ی سود هر سفارش قابل عددگذاری نیست؛ این داده‌ها در منابع موجود نیست.

آستانه یا رتبه؟ آستانه‌های ۰٫۳ تا ۰٫۷ هیچ مشتری را انتخاب نمی‌کنند، چون امتیازها از حدود ۰٫۰۵ بالاتر نمی‌روند. آستانه‌ای که روی آموزش برای انتخاب ۱۷٫۴٪ تنظیم شد، روی آزمون فقط ۱۵٫۰٪ را انتخاب کرد؛ پس برای ظرفیت ثابت باید فهرست را با رتبه‌بندی و برداشتن k نفر اول ساخت. امتیازها نیز احتمال واقعی نیستند: معیار `Brier` مدل با نرخ ثابت برابر است (۰٫۰۱۰۰).

۶. تفسیر، محدودیت‌ها و اقدام بعدی



شکل ۵ — اهمیت جایگشتی ویژگی‌ها (افت `Average Precision`) روی بخش‌های اعتبارسنجی آموزش.

اهمیت ویژگی‌ها: `history` بیشترین افت را دارد (۰٫۰۰۴۸ ± ۰٫۰۰۵۹) و `recency` بعد از آن است (۰٫۰۰۱۹ ± ۰٫۰۰۲۳)؛ ولی هر دو حدود یک انحراف معیار یا کمتر از آن‌اند و بقیه‌ی ویژگی‌ها نزدیک صفر. با ۴۶۳ خریدار آموزش، رتبه‌بندی دقیق ویژگی‌ها ممکن نیست. این‌ها همبستگی‌اند و نشان نمی‌دهند تغییر `history` یا `recency` علت خرید است.

نکته‌ی احتیاطی: بالاترین امتیازها در فهرست مربوط به مشتریانی با کمترین `history` (۲۹٫۹۹)، منطقه‌ی `Urban` و کانال `Web` است. در آموزش، این گروه ۶٫۴٪ می‌خرد (۱۳ از ۲۰۲) در برابر ۰٫۹۵٪ برای بقیه. تعداد خریدار پشت آن کم است و فقط یک فرضیه برای تأیید با داده‌ی جدید است.

گروه‌بندی ارزش × امتیاز (توصیفی، روی آزمون)

گروه	تعریف	مشتریان	خریداران	نرخ خرید
Priority	ارزش بالا، امتیاز بالا	۱٫۶۸۱	۳۱	۱٫۸٪
Growth	ارزش پایین، امتیاز بالا	۶۲۲	۱۷	۲٫۷٪
Retention	ارزش بالا، امتیاز پایین	۳٫۹۷۲	۲۹	۰٫۷٪
Low priority	ارزش پایین، امتیاز پایین	۵٫۲۱۳	۳۸	۰٫۷٪

ارزش = `history` بالاتر از میانه‌ی آموزش؛ امتیاز بالا = ۲۰٪ بالای امتیازهای آزمون. نرخ‌ها توصیفی‌اند و از ۱۷ تا ۳۸ خریدار در هر گروه آمده‌اند؛ علّی نیستند.

محدودیت‌ها

- نبود شناسه‌ی مشتری؛ نتایج در سطح ردیف است.
- عدم‌توازن کلاس و تعداد کم خریدار آزمون (۱۱۵)؛ همه‌ی برآوردها نوسان زیادی دارند.
- حذف ردیف‌های تکراری نرخ خرید را از ۰٫۹۰٪ به حدود ۱٫۰۱٪ رسانده است.
- آزمون جدید در یک دیتاست و دوره‌ی زمانی است؛ اعتبارسنجی مستقل در دوره‌ی آینده انجام نشده.
- امتیازها کالیبره نیستند و فقط برای رتبه‌بندی‌اند.
- اطلاعات اقتصاد کمپین (هزینه‌ی ایمیل، حاشیه‌ی سود) در داده نیست.
- افزودن `segment` به رگرسیون لجستیک، `AUC` اعتبارسنجی را از ۰٫۵۸۵ به ۰٫۶۱۴ می‌برد؛ این فقط همبستگی با گروه کمپین است، نه اثر علّی، و `segment` پیش از کمپین در دسترس نیست.

بخش پیشرفته (تکمیل‌نشده)

- **پیش‌بینی دومرحله‌ای مبلغ خرید** (احتمال خرید، سپس مبلغ مورد انتظار بین خریداران و ترکیب این دو) در پروژه اجرا نشده است. هیچ برآورد درآمدی در این گزارش وجود ندارد.
- حتی اگر انجام شود، درآمد پیش‌بینی‌شده‌ی تاریخی با **درآمد افزایشی ناشی از ایمیل** فرق دارد.
- `Uplift Modeling` در کاتالوگ امتیاز اضافه و اختیاری است و اجرا نشده؛ از کارهای اجباری جداست.

وضعیت آمادگی و کارهای لازم پیش از استفاده‌ی واقعی (به ترتیب اولویت)

جمع‌بندی وضعیت: پروژه از نظر روش‌شناسی مدل‌سازی (نشت، تقسیم، اعتبارسنجی) قابل دفاع است، اما برای استقرار عملیاتی آماده نیست.

1. **آزمون کنترل‌شده‌ی کمپین (`A/B Test`):** تنها راه سنجش اثر واقعی ایمیل؛ بدون آن فقط اولویت‌بندی بر اساس تمایل به خرید داریم.
2. **ساخت رتبه‌بندی نهایی روی فهرست واقعی مشتریان با شناسه‌ی یکتا:** با یک مدل و یک رویه‌ی امتیازدهی؛ خروجی فعلی فقط نمونه‌ی ارزیابی روی ردیف‌هاست.
3. **تکمیل معیارهای ارزیابی:** `Accuracy`، `F1` و ماتریس خطا برای هر چهار مدل در اعتبارسنجی (اکنون گزارش‌نشده‌اند).
4. **اعتبارسنجی در دوره‌ی زمانی بعد** و جمع‌آوری آزمون با خریداران بیشتر.
5. **جمع‌آوری هزینه‌ی ایمیل و حاشیه‌ی سود** برای تحلیل هزینه‌ی `FP` و `FN`.
6. در صورت نیاز: پیش‌بینی مبلغ خرید و `Uplift Modeling` (اختیاری).

یادداشت تطبیق اعداد: مقدار `XGBoost` در خلاصه‌ی مدیریتی PDF و README پروژه (AP برابر ۰٫۰۰۳۲ ± ۰٫۰۱۸۷، `Lift` برابر ۱٫۶۱، AUC برابر ۰٫۶۱۶) با جدول ذخیره‌شده‌ی نوت‌بوک ۳ (AP برابر ۰٫۰۰۲۱ ± ۰٫۰۱۷۶، `Lift` برابر ۱٫۶۵، AUC برابر ۰٫۶۰۹) یکی نیست. این گزارش مقدار جدول ذخیره‌شده را به‌کار برده است. انتخاب جنگل تصادفی تغییر نمی‌کند، ولی README، خلاصه‌ی PDF و متن‌های نوت‌بوک باید با خروجی ذخیره‌شده هماهنگ شوند.